

클린업 2주차

3팀 선형대수학

황정현
고경현
김지민
반경림
전효림

선형변환으로의 해석

- 선형변환 전후의 넓이 관계 설명

지난주 이야기!



‘선형변환’의 관점에서 바라본 선형방정식 $Ax = b$

$$\begin{matrix} A & x \\ \begin{pmatrix} 2 & -3 \\ 1 & 1 \end{pmatrix} & \begin{pmatrix} 1 \\ 1 \end{pmatrix} \end{matrix} = \begin{matrix} b \\ \begin{pmatrix} -1 \\ 2 \end{pmatrix} \end{matrix}$$

벡터 x 에 행렬 A 를 곱하는 선형변환을 통해 벡터 b 만들

input

벡터 x 가 만드는
공간의 넓이

Linear Transformation

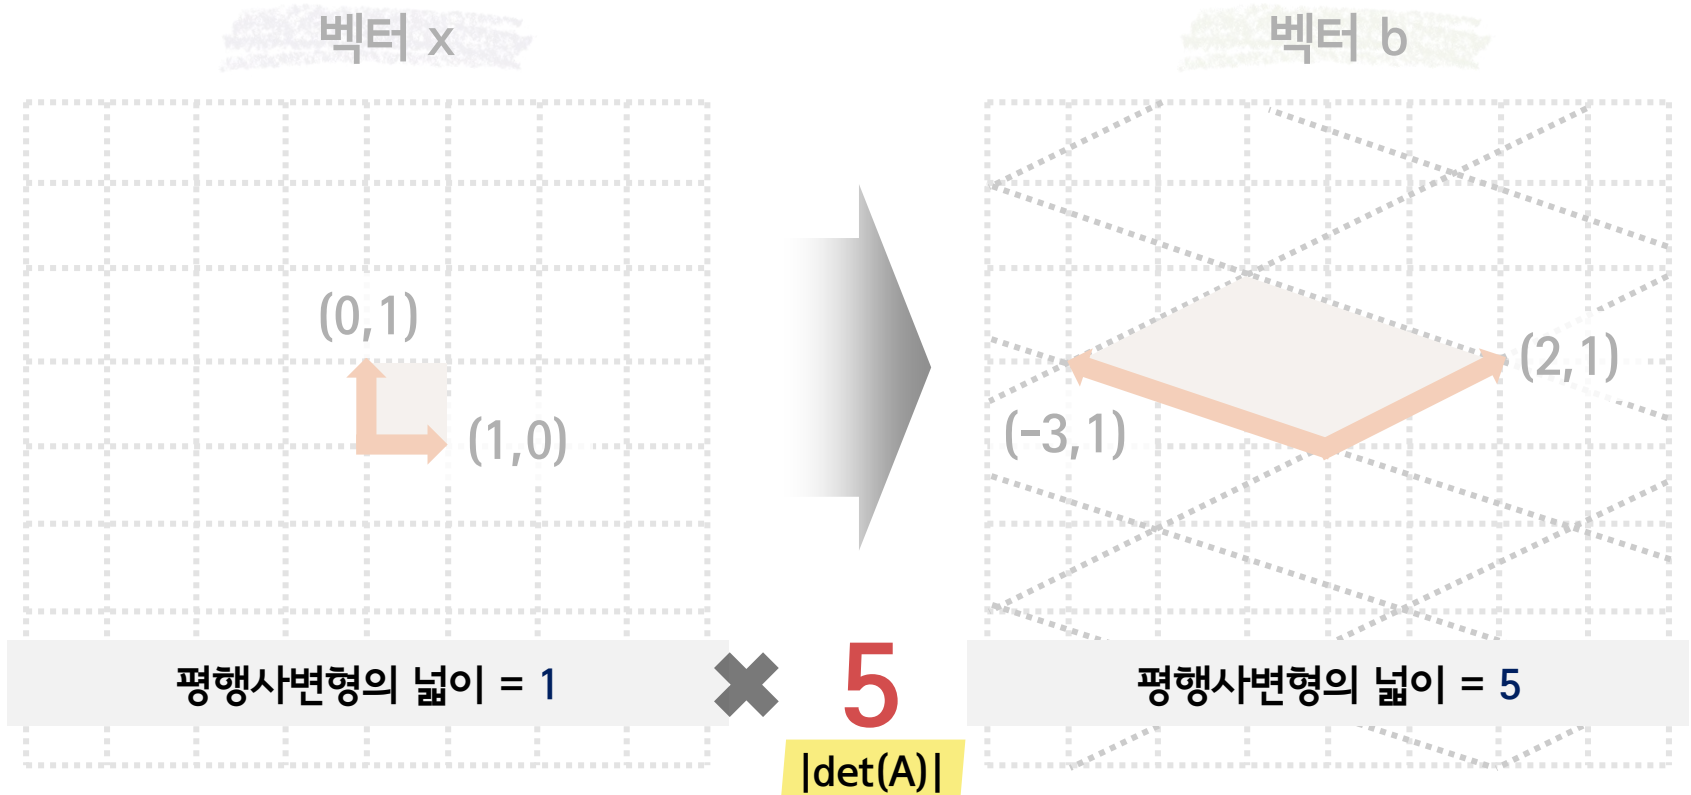
$|\det(A)|$ 배 변화

output

벡터 b 가 만드는
공간의 넓이

선형변환으로의 해석

- 선형변환 전후의 넓이 관계 설명




선형변환으로의 해석

Q

그렇다면 $\det(A)$ 가 0인 것은 무엇을 뜻하나요?



선형변환을 통해 **공간이 압축**되었다!



차원이 바뀌면 기존 공간에서의 부피/넓이는 0이 됨

선형부분공간

subspace

벡터공간

선형부분공간

span

column space

\mathbb{R}^n

선형부분공간

- 벡터공간 안의 몇 가지 벡터 집합으로 이루는 또다른 부분 벡터공간



선형 조건



0벡터(원점)가 존재한다

선형부분공간 내 벡터에 다른 벡터를 **합**한 것도 선형부분공간에 존재한다

선형부분공간 내 벡터에 **상수를 곱**한 것도 선형부분공간에 존재한다

선형부분공간

벡터공간

선형부분공간

subspace




span

column space



2차원 공간에서 축을 포함한 제1사분면은

선형부분공간이 될 수 있을까?



선형부분공간이 아니다! 💧

선형부분공간

벡터공간

선형부분공간




subspace

span

column space

그렇다면 2차원 공간에서의 직선 l 은

선형부분공간이 될 수 있을까?



선형부분공간이다!



선형부분공간


벡터공간

선형부분공간

span

column space

- 벡터 a_1, a_2, \dots, a_n 의 모든 선형결합이 속하는 선형부분공간



v_1 과 v_2 의 합과 상수배로
만든 모든 조합

$\text{span}\{v_1, v_2\}$

3차원 공간에서
원점을 지나는 평면

선형부분공간


벡터공간

선형부분공간

span

column space

- 행렬 A 의 열벡터의 연산으로 만드는 공간
- 행렬 A 의 **열벡터의 span**



$Ax = b$ 의 해가 있다

$col(A)$ 가 모든 Ax 를 포함한다

벡터 b 가 $col(A)$ 에 있다

벡터 b 가 $span\{a\}$ 에 있다

Null space

영공간
Null Space

해가 없다



$Ax = 0$ 을 만족하는 해 x 가 이루는 공간,
즉 homogenous한 방정식의 해의 집합

$$Ax = 0$$

homogenous

일치한다

Consistent x 가 모두 0

해가 유일하다

trivial solution

해가 무수히 많다

non-trivial solution

Null space

$$\begin{matrix} & A & \\ \begin{pmatrix} 1 & 0 & 1 \\ 1 & 1 & 2 \\ 0 & 1 & 1 \end{pmatrix} & \begin{pmatrix} x \\ y \\ z \end{pmatrix} & = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}
 \end{matrix}$$

Null
space

$Ax = 0$ 을 만족시키는 **해**들을 모아 형성한 공간

0벡터



해벡터끼리의 합



해벡터의 상수배

선형부분공간
방정식의 해벡터가 \mathbb{R}^n 그것의 null space는 \mathbb{R}^n 의 선형부분공간

기저

1 선형독립 *independence*

- $c_1x_1 + c_2x_2 + \cdots + c_nx_n = 0$ 에서 c 가 모두 0인 경우를 제외한 어떠한 c_i 의 조합으로도 식이 성립되지 않는 경우



$$A x = 0$$

- 선형방정식을 만족하는 벡터 x 가 오직 0벡터뿐인 경우



- Null space에 0벡터만 있는 경우



기저

2 기저 Basis

span



선형독립

어떤 공간을 구성하는 span 벡터의 **최소** 집합벡터공간을 **효율적**으로 표현할 수 있는 벡터들(span)어떤 공간을
span하는
기저는
유일하지 않음

기저

3 Null space의 기저

- 자유변수를 상수로 하는 선형조합의 벡터

null space의
기저 개수



자유변수 개수



$n - (\text{pivot 개수})$

$$x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} -x_2 - 2x_4 \\ x_2 \\ x_4 \\ x_4 \end{bmatrix} = s \begin{bmatrix} -1 \\ 1 \\ 0 \\ 0 \end{bmatrix} + t \begin{bmatrix} -2 \\ 0 \\ 1 \\ 1 \end{bmatrix}$$

자유변수 기저

기저

4 Column space의 기저

- RREF의 **pivot**이 위치하는 원래 행렬의 열

column space의
기저 개수



pivot의 개수


$$A = \begin{pmatrix} 1 & 1 & 0 & 2 \\ -2 & -2 & 1 & -5 \\ 1 & 1 & -1 & 3 \\ 4 & 4 & -1 & 9 \end{pmatrix}$$

col(A)의 기저

$$R = \begin{pmatrix} 1 & 1 & 0 & 2 \\ 0 & 0 & 1 & -1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

독립

차원과 rank



	Null space	Column space
<i>dimension</i>	자유변수 개수 pivot이 없는 열 개수	pivot 개수

$\text{rank}(A)$

투영벡터 (Projection)



벡터 b 를 직선 a 위의
벡터로 매핑



벡터 b 의 직선 공간으로의
공간압축



공간압축
선형변환



투영벡터 (Projection)

벡터 b 를 직선 a 위의
벡터로 매핑


벡터 b 의 직선 공간으로의
공간압축

공간압축
선형변환



벡터 b 의
 $\text{span}\{a\}$ 상의
정사영
'Proj_{ab}'

실제값(b)과 예측값(p)의 차이인 e 와
벡터 a 가 직교함을 이용하여 계산




투영벡터와 Least Square Method

최소자승법

Least Square Method

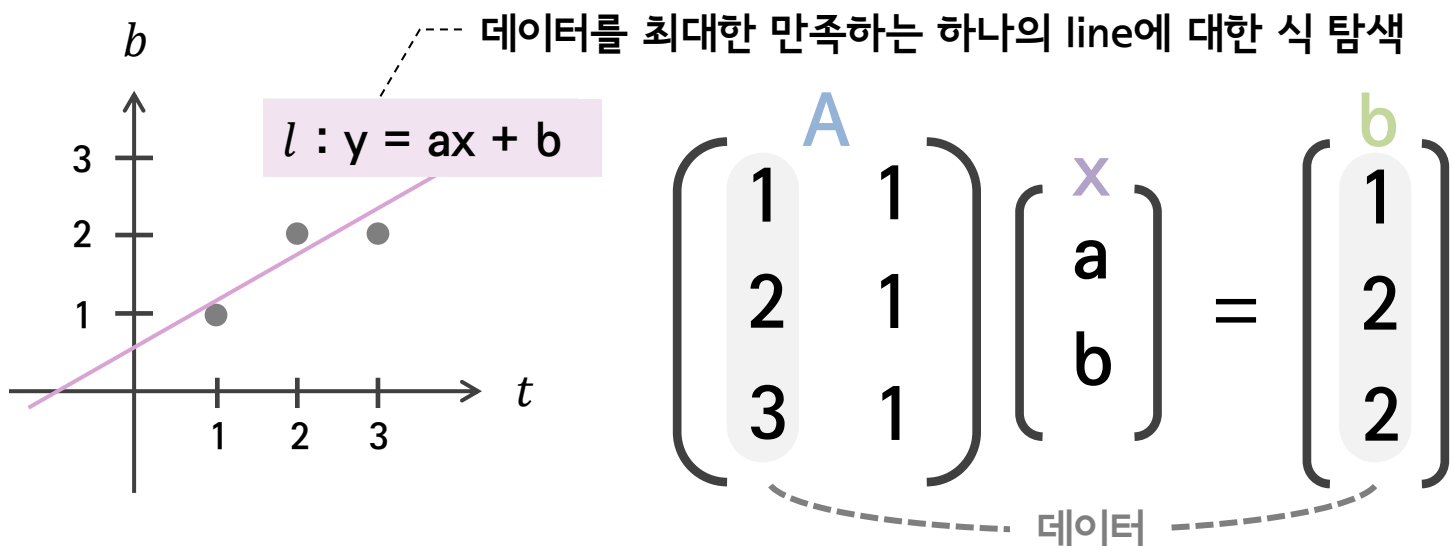
$Ax = b$ 의 해가 없는 경우 **최소 거리**를 바탕으로
가장 근접한 $A\hat{x} = \hat{b}$ 의 해 \hat{x} 를 구하는 것



투영벡터와 Least Square Method

최소자승법

Least Square Method

 $Ax = b$ 의 해가 없는 경우 **최소 거리**를 바탕으로가장 근접한 $A\hat{x} = \hat{b}$ 의 해 \hat{x} 를 구하는 것

선형회귀분석

1 회귀식 $y = \beta_0 + \beta_1 x$ 형태 바꾸기

꼭 기억하라구 ~ㅎ



회귀분석에서는 **Least Square Method**를 통해

회귀식 $X\beta = y$ 의 **간접해** $\hat{\beta}$ 를 구함으로써

실제값(y)과 예측값(\hat{y} , $X\hat{\beta}$)의 거리(**residual**)를

최소화하는 회귀식을 구하는 것이 목표!

$X\beta$ 와 y 의 최소 거리 고려

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

가중회귀모델

- 단순선형회귀식 •

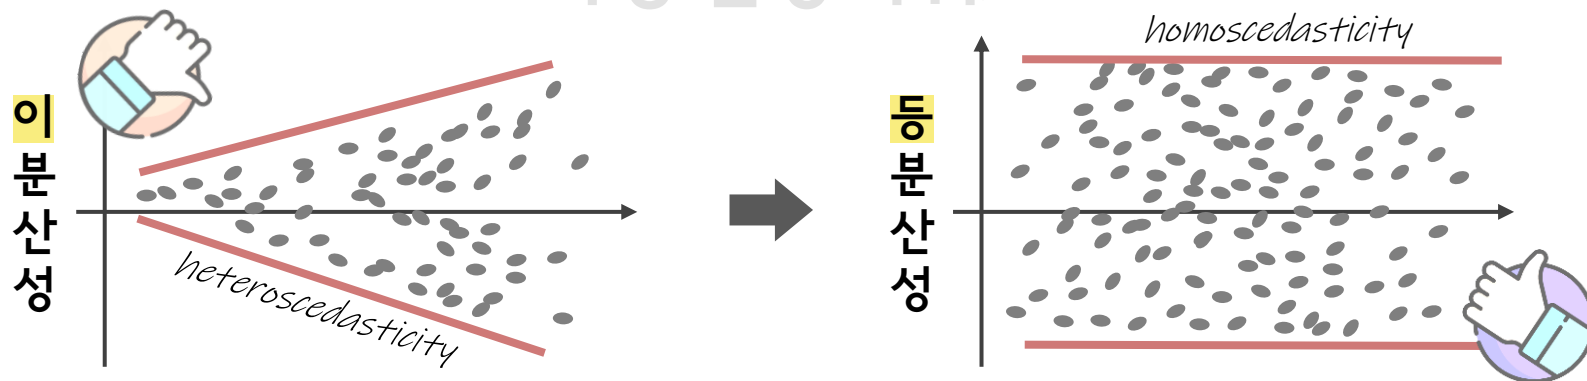
$$y = X\beta + \varepsilon$$

residual

작은 분산에 가중치를 두어

등분산성을 만족하게끔 처리한 후 회귀분석 진행

가중선형회귀



가중회귀모델

$$\begin{array}{ccc}
 \begin{pmatrix} w_1 & 0 & \cdots & 0 \\ 0 & w_1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & w_n \end{pmatrix} & \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} & \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} \\
 \textcolor{red}{W} & X & \beta
 \end{array} = \begin{array}{cc}
 \begin{pmatrix} w_1 & 0 & \cdots & 0 \\ 0 & w_1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & w_n \end{pmatrix} & \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \\
 \textcolor{red}{W} & y
 \end{array}$$

양변에 가중치를 곱한 뒤 Least Square Method를 적용해 베타계수 추정

$$\hat{\beta} = ((WX)^T WX)^{-1} (WX)^T W y$$



기존 선형회귀 모형



가중치 행렬 $\textcolor{red}{W}$

가중회귀모델



두 회귀모형의 비교



	단순선형회귀	가중회귀
SSE	$\ y - \hat{y}\ ^2 = \ y - X\hat{\beta}\ ^2$	$\ W y - W \hat{y}\ ^2 = \ W y - W X \hat{\beta}\ ^2$
β 의 해	$X^T X \hat{\beta} = X^T y$	$(W X)^T W X \hat{\beta} = (W X)^T W y$

기존 선형회귀 모형

가중치 행렬 W